一、專題摘要 (解釋實作與說明需要解決的問題，限 300~500 字。)

1. 期末專題主題

- 爬取 PTT 政黑板約前 500 篇文章及每篇文章推文，並做簡單整理

2. 期末專題基本目標

- 爬取 PTT 政黑板文章
- 整理全部的文章，了解最近趨勢、熱門關鍵字
- 整理發/推文者其全部的發/推文，進一步用 jieba 抓取關鍵字
- 整理有使用相同 ip 的推/發文者，猜測推/發文者是否有關聯

二、實作方法介紹 (介紹使用的程式碼、模組，並附上實作過程與結果的截圖，需圖文並茂。)

1. 使用的模組介紹

In [1]:
```
import requests
import re
import json
from urllib.parse import urljoin
from bs4 import BeautifulSoup
import _thread
import time
import jieba
import jieba.analyse
from collections import Counter
from wordcloud import WordCloud
import pandas as pd
import matplotlib.pyplot as plt

# PTT 八卦版網址
#PTT_URL = 'https://www.ptt.cc/bbs/Gossiping/index.html'
PTT_URL = 'https://www.ptt.cc/bbs/HatePolitics/index.html'
```

2. 介紹使用的程式碼(完整程式碼請參閱最後 github 連結)

- 定義爬 PTT
- 使用 Crawl_article 以及 crawl_comment

In [2]:
```
def crawl_article(url):
    response = requests.get(url, cookies={'over18': '1'})
    response.encoding = 'utf-8'

    # 假設網頁回應不是 200 OK 的話, 我們視為傳送請求失敗
    if response.status_code != 200:
        print('Error - {} is not available to access'.format(url))
        return
```

In [3]:
```
def crawl_comment(amount=50):

    all_data = []
    comments = []
    nextPage = PTT_URL

    while len(all_data) <= amount:
        # 對文章列表送出請求並取得列表主體
        resp = requests.get(nextPage, cookies={'over18': '1'})
        resp.encoding = 'utf-8'

        soup = BeautifulSoup(resp.text, 'html5lib')
        main_list = soup.find('div', class_='bbs-screen')

        nextPage = soup.find('div', 'btn-group btn-group-paging').find_all('a')[1]['href']
        nextPage = 'https://www.ptt.cc' + nextPage
```

In [10]:
```
import time

start = time.time()
data, comments = crawl_comment(500)
save_data(data)
print('time difference:', time.time() - start)
```

```
Parse Re: [討論] 居住正義要怎麼做才能成功？ - https://www.ptt.cc/bbs/HatePolitics/M.1600829274.A.C8D.html
Parse Re: [討論] 為何瘋狂酸蔡英文好遘？ - https://www.ptt.cc/bbs/HatePolitics/M.1600829839.A.091.html
Reach the last article of this page
Parse [黑特] 4%黨召委要投給KMT - https://www.ptt.cc/bbs/HatePolitics/M.1600826178.A.7E5.html
Parse [新聞] 為什麼日本擔憂北海道變成中國的？中國爆買了多少？目的何在 - https://www.ptt.cc/bbs/HatePolitics/M.1600826569.A.D25.htm
l
Parse [黑特] 檢舉魔人？亂開罰？蔡英文政府官遘民反！ - https://www.ptt.cc/bbs/HatePolitics/M.1600826829.A.DE7.html
Parse [討論] 居住正義要怎麼做才能成功？ - https://www.ptt.cc/bbs/HatePolitics/M.1600826838.A.11C.html
Parse Re: [討論] 為何瘋狂酸蔡英文好遘？ - https://www.ptt.cc/bbs/HatePolitics/M.1600827017.A.C58.html
Parse [新聞] 馬英九：美航母艦齡老化　台海若發生戰 - https://www.ptt.cc/bbs/HatePolitics/M.1600827256.A.DDE.html
Parse Re: [討論] 蔡同學論文現在是在改錯字大賽嗎 - https://www.ptt.cc/bbs/HatePolitics/M.1600827291.A.A8A.html
Parse Re: [黑特] 4%黨召委要投給KMT - https://www.ptt.cc/bbs/HatePolitics/M.1600827578.A.769.html
Parse Re: [黑特] 歷任的總統有像蔡英文遘樣嗎? - https://www.ptt.cc/bbs/HatePolitics/M.1600827674.A.E1C.html
Parse [黑特] 蔡英文就是好遘，為什麼不能酸？ - https://www.ptt.cc/bbs/HatePolitics/M.1600827871.A.07A.html
Parse [新聞] 苗博雅引用大雄、胖虎諷侯友宜 侯：不必襲 - https://www.ptt.cc/bbs/HatePolitics/M.1600827895.A.DC9.html
Parse Re: [討論] 為何瘋狂酸蔡英文好遘？ - https://www.ptt.cc/bbs/HatePolitics/M.1600828000.A.CF1.html
Parse [新聞] 高市掛「你超速、爽國庫」今被當違規拆除 - https://www.ptt.cc/bbs/HatePolitics/M.1600828142.A.85E.html
Parse [黑特] 盧秀燕對台中房價放手耶，瘋了嗎 - https://www.ptt.cc/bbs/HatePolitics/M.1600828152.A.1D2.html
Parse [討論] 解政黑每日任務有什麼獎勵阿? - https://www.ptt.cc/bbs/HatePolitics/M.1600828209.A.666.html
```

運用 jiebraWord 與 jiebaCount，讀取推文與發文中，最常出現的詞彙

In [6]:
```
def jiebaWord(content, topk=20):
    #斷詞並且統計每個詞彙出現的頻率

    regStr = '\s+|[0-9a-zA-Z_\{\}\(\)（）\./:~\=]+'
    regex = re.compile(regStr)

    jieba.set_dictionary('dict.txt.big') # 使用繁體辭庫
    jieba.load_userdict('user_dict.txt')  #自定義詞典
    jieba.analyse.set_stop_words('cn_stopwords.txt')

    stopWords = getStopWord()

    words = jieba.cut(content, cut_all=False)

    filterWords_list = [ w for w in words if w not in stopWords and not regex.match(w)]
    filterWords_str = ''.join(filterWords_list)

    tags = jieba.analyse.extract_tags(filterWords_str, topk)

    count = []
    for t in tags:
        count.append(filterWords_list.count(t))
    tagspd = pd.DataFrame([tags, count]).T
    tagspd = tagspd.rename({0:'KeyWords', 1:'Times'}, axis='columns')
    return tagspd, tags

def jiebaCount(data, columnName, topK = 20):
    #透過此function過濾資料，使用jiebaWord斷詞
    all_content = ''

    for d in data:
        all_content += d[columnName]

    content_pd, content_tags = jiebaWord(all_content, topK)

    return content_pd, content_tags
```

In [11]:
```
content_pd, content_tags = jiebaCount(data, 'article_content', 40) #看看發文中，最常出現的詞彙
message_pd, message_tags = jiebaCount(comments, 'push_content', 40) #看看推文中，最常出現的詞彙
```

```
Building prefix dict from C:\Users\10904085\Desktop\cupoy\web\Final(PTT)\dict.txt.big ...
Dumping model to file cache C:\Users\10904085\AppData\Local\Temp\jieba.udfa9e734b7eb9a15dde63142dd63170e.cache
Loading model cost 1.074 seconds.
Prefix dict has been built successfully.
Building prefix dict from C:\Users\10904085\Desktop\cupoy\web\Final(PTT)\dict.txt.big ...
Loading model from cache C:\Users\10904085\AppData\Local\Temp\jieba.udfa9e734b7eb9a15dde63142dd63170e.cache
Loading model cost 1.094 seconds.
Prefix dict has been built successfully.
```

利用 wordcouldPTT 取得貼文與推文的文字雲，了解最常出現的 40 個詞彙

In [7]:
```
def wordcloudPTT(tags):
    text = " ".join(tags)
    font_path = 'msjh.ttc'
    #font_path = 'hi.ttf'
    wordcloud = WordCloud(width=1200, height=600, max_font_size=200, max_words=200,
                          background_color='black', font_path=font_path, colormap='Dark2').generate(text)
    plt.figure(dpi=600)
    plt.imshow(wordcloud)
    plt.axis('off')
    plt.show()
```

利用 CollectUserInfo 以及 CollectIPinfo
整理最常發文的 ip, id，或是最常推文的 id

In [8]:
```
def CollectIPInfo(inputData, author_ip, author_id, times):
    #觀察每個IP有多少人使用來發文/推文

    ipList = list()

    for ip in inputData[author_ip]:
        if not ip in ipList:
            ipList.append(ip)

    tempPd = pd.DataFrame(ipList)
    tempPd = tempPd.rename({0:author_ip}, axis='columns')

    user_id = []       # 裝每個發/推文者的id
    authorCount = []      # 裝每個ip的推/發文數或推/發文人數


    for ip in ipList:
        tempData = inputData[inputData[author_ip] == ip]
        tempList = list()

        #計算同一個ip，總共有幾個人使用，同id只算一次
        for identification in tempData[author_id]:
            if identification not in tempList:
                tempList.append(identification)

        user_id.append(';'.join(tempList))
        authorCount.append(len(tempList))

    tempPd[author_id] = user_id
    tempPd[times] = authorCount
    tempPd = tempPd.sort_values(by=times, ascending=False).reset_index()

    return tempPd
```

In [9]:
```
def CollectUserInfo(inputData, author, content, times):
    #觀察每個id發了多少文章/推了多少文章

    authorList = list()

    for person in inputData[author]:
        if not person in authorList:
            authorList.append(person)

    tempPd = pd.DataFrame(authorList)
    tempPd = tempPd.rename({0:author}, axis='columns')

    allArticles = ''
    count = 0
    user_id = []       # 裝每個發/推文者的id
    articleCount = []      # 裝每個id的推/發文數或推/發文人數


    for person in authorList:
        tempData = inputData[inputData[author] == person]

        # 取得同author的所有文章內容，並且計算總共發了幾篇文章
        for info in tempData[content]:
            allArticles += info + ' '

            if len(user_id) > count:
                user_id[count] = user_id[count] + ';' + info
            else:
                user_id.append(info)

        articleCount.append(len(tempData[content]))
        count += 1

    tempPd[content] = user_id
    tempPd[times] = articleCount
    tempPd = tempPd.sort_values(by=times, ascending=False).reset_index()

    return tempPd
```

三、成果展示 (介紹成果的特點為何，並撰寫心得。)

1. 特點

- 利用 pandas 整理每個推/發文者的全部推/發文及每個 ip 對應的使用者

2. 成果

發文的文字雲

推文的文字雲

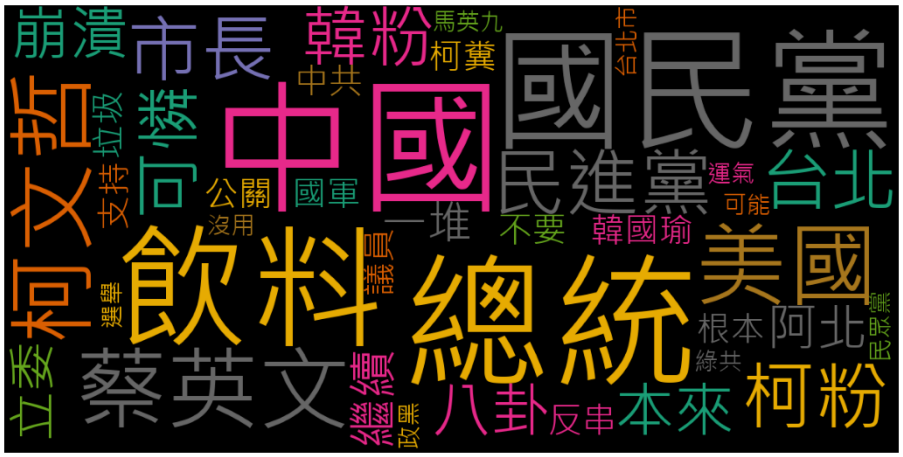

下列則為發文最多，推文最多，發文最多 id，推文最多 id，以及發文最多日期的詳細表格資料

```
In [23]: most_article_user = CollectUserInfo(pddata, 'article_author_id', 'article_content', 'article_times')
         most_push_user = CollectUserInfo(pdmessage, 'push_userid', 'push_content', 'push_times')
```

```
In [24]: most_ip_author = CollectIPInfo(pddata, 'ip', 'article_author_id', 'author_count')
         most_ip_push = CollectIPInfo(pdmessage, 'push_ipdatetime', 'push_userid', 'push_userid_count')
         most_pushCount_date = CollectIPInfo(pdmessage, 'push_ipdate', 'push_userid', 'push_userid_count')
```

```
In [25]: most_article_user
```

Out[25]:

	index	article_author_id	article_content	article_times
0	51	nicholas0406	奇怪了 很多柯粉一直認為說\n\n民進黨怕柯文哲選2024 所以派1450 綑軍出來打壓柯文...	9
1	48	FoRTuNaTeR	https://upload.cc/i1/2020/09/23/Ah1MXe.jpg 此舉等...	8
2	27	Zionward	館長溫柔提醒\n　目前已有專業保鏢守護\n　　接近館長20公尺內，切勿有攻擊意圖及動作\n　...	7
3	64	Gavatzky	首先\n\n各位對戰爭要有兩種認知\n\n第一個\n\n戰爭中絕對沒有哪一個國家是穩贏的\n...	7
4	50	Rrrxddd	餓死拍頭\n\n為什麼台北發生火災\n台中發生氣爆 這樣的事情\n卻引起不了共鳴？\n\n一...	7
...	...	...	...	...
251	136	lemon0970	于北辰今天說 國民黨沒有誘因讓年輕人加入\n\n認為說台灣就是獨台獨 而蔡英文很厲害\n...	1
252	137	Acalanatha	3年前，只要黑阿北的，個個死無葬身之地，\n\n最有名的就那個問肚臍英文怎麼拼的誰誰誰啦\n...	1
253	141	haehae311444	話說 某人講的公關公司這波操作 我真的不懂\n讓我覺得根本是在騙錢的吧\n說做秀 哪個政治人...	1
254	142	Yolosnow	https://i.imgur.com/n1f3TZQ.jpg 蔡英文買個飲料就在那邊酸\n...	1
255	255	remora	1.新聞網址 https://udn.com/news/story/9750/4877036...	1

256 rows × 4 columns

```
In [26]: most_push_user
```

Out[26]:

	index	push_userid	push_content	push_times
0	346	FoRTuNaTeR	還好，妳沒看過這照片;https://upload.cc/i1/2020/08/08/Oxn...	957
1	0	WTF55665566	同意這一點;但屬屋供給可以同步處理吧？不然推公宅的用意是？;不意外垃圾 小紅;蠶天嗆任小綠 ...	334
2	436	foolfighter	賺到不知人;阿北怎麼沒有領獎？？？;八卦柯冀意外嗎？ 根本就yahoo化;柯狗死豬不怕滾水燙...	267
3	21	Moratti	要賭蔡安帶 他們的議員候選人跑行程吧,他的好運 被2018的三千票給斃了;對啊 如果揮的人是...	266
4	169	EggAcme	所以柯韓粉有證據是店家演的?有證據就拿出來阿?還是現在;柯韓粉指控都不用有證據，憑我感覺就可...	233
...	...	...	...	...
1527	937	autokey	誰看的出來是公家掛的~????????	1
1528	943	fxntdsxdr	這篇還真多邏輯大師	1
1529	946	leader223	你得到他了	1
1530	948	Wcw5504	這是印度故意報來噁心中國的吧	1
1531	1531	superprada	沒有觀眾緣，真慘	1

1532 rows × 4 columns

```
In [27]: most_ip_author
```

Out[27]:

	index	ip	article_author_id	author_count
0	0	223.140.254.110	hagousla	1
1	209	59.120.195.222	tigerzz3	1
2	216	111.240.123.4	RX00	1
3	215	114.27.114.48	pqbd22	1
4	214	101.12.20.105	Saint0822	1
...	...	...	...	...
312	105	1.160.82.71	XindeX	1
313	104	101.14.193.73	a520	1
314	103	49.214.180.77	andycat5566	1
315	102	118.150.253.173	goetze	1
316	316	101.137.38.123	CavendishJr	1

In [28]:
```
most_ip_push
```

Out[28]:

	index	push_ipdatetime	push_userid	push_userid_count
0	1127	09/22 13:23	Moratti;DarthCod;obey1110;Atkins13;boogieman;d...	21
1	1111	09/22 13:20	windom;WTF55665566;takuminauki;Atkins13;Moratt...	21
2	1300	09/22 10:58	gunng;ianbh;castalchen;tigerzz3;FoRTuNaTeR;Cav...	19
3	1376	09/22 10:28	lostman;Tiara5566;dakkk;yun0112;pbkfss;foolfig...	19
4	1110	09/22 13:19	windom;takuminauki;chenyei;zeuswell;boogieman;...	18
...	...	...	...	...
2013	1616	09/22 04:25	ota978	1
2014	1615	09/22 07:01	DameKyon	1
2015	1614	09/22 05:15	FoRTuNaTeR	1
2016	1613	09/22 04:10	FoRTuNaTeR	1
2017	2017	09/21 21:05	CavendishJr	1

2018 rows × 4 columns

In [29]:
```
most_pushCount_date
```

Out[29]:

	index	push_ipdate	push_userid	push_userid_count
0	2	09/22	platinum500a;pinacolada;Atkins13;virginia779;C...	1268
1	0	09/23	WTF55665566;latin0126;kairi5217;a2550099;uieas...	599
2	4	09/21	bruce2248;genheit;Moratti;MrJohn;wx190;elainak...	251
3	1	07/22	ubcs	1
4	3	192.192.154.43	luluhihi	1

四、結論 (總結本次專題的問題與結果)

- 不一定每個推文都會顯示其 ip
- 爬取文章需要較長時間，可以考慮利用 thread 加速，但須考慮網站的防衛機制，如果爬取速度過快可能會造成反效果
- 希望能做到分類每個字詞的傾向，不用去觀察發/推文者的全部關鍵字，就能了解每個發/推文者的傾向。
- 或是有關鍵詞庫網，不用自己定義太多文字

五、期末專題作者資訊 (請附上作者資訊)

1. 個人 Github 連結：https://github.com/garycjwu/1st-DL-CVMarathon/tree/master/Web_Crawler
2. 個人在百日馬拉松顯示名稱：Gary Wu